DA3-Giant：RGB / 热红外网络结构

当前热红外训练配置 · N = N_RGB + N_IR = 8 · H × W = 392 × 518 · Block 编号从 0 开始

RGB 多视角输入
[B, N_RGB, 3, H, W]

红外多视角输入
[B, N_IR, 3, H, W]

统一尺寸 / 中心裁剪
ImageNet 归一化

3 通道读取 / 统一尺寸 / 中心裁剪
ImageNet 归一化

按视角维 N 堆叠 → [B, N, 3, H, W]

共享 Patch Embedding + CLS token + 位置编码
14 × 14 patch → 1036 个 patch token / 图；特征维度 1536

共享 ViT-G：Block 0–12（前 13 层）
每张图内部独立做注意力；24 个注意力头，FFN = SwiGLU

RGB camera token
[1, 2, 1536]
参考视角 / 其他视角

按 thermal_mask 选择 camera token
替换每张图的 CLS token（进入 Block 13 前）

热红外 camera token
[1, 2, 1536]，可训练
从 RGB token 复制初始化

共享 ViT-G：Block 13–39（后 27 层）
Global Attention ↔ Local Attention 交替
奇数层：所有视角共同注意力，融合 RGB / 红外信息
偶数层：每张图内部注意力；原始权重冻结 + LoRA 可训练

LoRA × 27 层
attn.qkv / attn.proj
mlp.w12 / mlp.w3
r = 64，α = 128
dropout = 0.1

提取 Block 19 / 27 / 33 / 39 的四层特征
前一个 Local 特征 + 当前 Global 特征 → 1536 + 1536 = 3072 维

4 组 [B, N, 1036, 3072]

[B, N, 3072]

DualDPT：四层 Patch 特征 → 特征金字塔
投影 / 缩放 / 逐级融合；深度与 ray 使用独立融合分支

CameraDec：最后一层 camera token
两层全连接 + ReLU → t / q / FoV

深度图 + 深度置信度
每个视角各一张
[B, N, H, W]

Ray + Ray 置信度
当前路径计算后移除
不作为最终输出

相机外参 + 内参
外参：OpenCV w2c
内参：[B, N, 3, 3]

冻结的原始模块　可训练的新增参数　多视角特征融合　最终输出

仅训练热红外 camera token 和共享 LoRA：42,470,400 个参数；RGB 与红外均经过 LoRA。

依据 DA3base 当前 thermal_giant_sear 配置与源码；热红外加载路径已移除 Gaussian 分支。